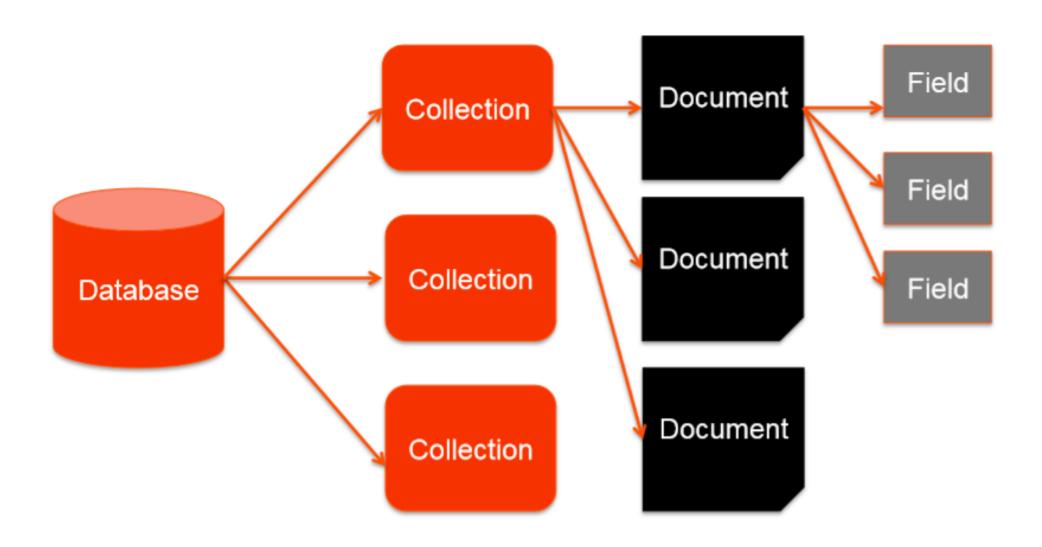
Modèle Document

- Principes
- MongoDB

Base de données documents

- Basé également sur le paradigme [clé, valeur], mais avec une valeur, de type document
- Document : structure arborescente contenant une liste de champs
- Champs est associé à une valeur qui peut elle même être une liste
- Documents principalement de type JSON ou XML
- Représentation d'un document :
 - Forme sérialisée (la plus courante) : contenu marqué par des balises ou par des accolades ouvrante/fermante.
 - Forme arborescente

Collection de documents



Document JSON

Forme sérialisée

```
"fruits": [
 { "kiwis": 3,
  "mangues": 4,
  "pommes": null
 { "panier": true }
"legumes": {
  "patates": "amandine",
  "poireaux": false
 "viandes": ["poisson", "poulet", "boeuf"]
```

Forme arborescente



Base de données documents : cas d'utilisation

Cas d'utilisation :

- Systèmes de gestion de contenu (profils utilisateurs, avis et commentaires, blogs, etc.)
- Applications de e-commerce (stockage du catalogue, schéma flexible pour les produits et commandes)

Non applicable aux:

- Données interconnectées
- Données non-structurées

Principaux moteurs orientés document

☐ include secondary database models

53 systems in ranking, February 2022

	Rank			-	Score	
Feb 2022	Jan 2022	Feb	DBMS	Database Model		Jan Feb
1.	1.	1.	MongoDB 🔠	Document, Multi-model 🚺	488.64 +0).07 +29.69
2.	2.	2.	Amazon DynamoDB 🚹	Multi-model 🛐	80.36 +0).50 +11.21
3.	3.	3.	Microsoft Azure Cosmos DB 🖽	Multi-model 👔	39.95 -0).09 +8.29
4.	4.	4.	Couchbase 🗄	Document, Multi-model 🔃	30.07 +1	-0.59
5.	5.	5.	Firebase Realtime Database	Document	19.15 -0).21 +3.15
6.	6.	6.	CouchDB	Document, Multi-model 🚺	17.45 +0).81 +1.84
7.	1 8.	7.	MarkLogic	Multi-model 👔	9.46 +0).27 +0.00
8.	4 7.	8.	Realm 🔡	Document	9.42 -0).17 +0.27
9.	9.	9.	Google Cloud Firestore	Document	9.06 +0	0.14 +1.01
10.	1 2.	↑ 11.	ArangoDB 🚹	Multi-model 🛐	5.40 +0).67 +0.33
11.	4 10.	1 20.	Virtuoso 🗄	Multi-model 👔	5.39 +0).02 +3.02
12.	4 11.	12.	Google Cloud Datastore	Document	5.25 +0	0.41 +0.23
13.	13.	↓ 10.	OrientDB	Multi-model 👔	5.03 +0	0.47 -0.10
14.	14.	4 13.	Oracle NoSQL	Multi-model 👔	4.84 +0).43 +0.33

MongoDB

- Base de données orientée documents (représentation structurée)
- Open source développé par MongoDB Inc depuis 2007
- Nom provenant de l'anglais "humongous" ("énorme")
- Ecrit en C++
- *Mongo Atlas* : mode hébergé dans le cloud sur la base d'une tarification horaire
- Stockage des documents au format BSON (*Binary Serialized dOcument Notation* ou *Binary* JSON) mais structure visible par les utilisateurs en JSON

MongoDB: liens utiles

- Site officiel: https://www.mongodb.com/fr
- Documentation: : https://docs.mongodb.com/manual/introduction/
- Console en ligne dans la documentation :

```
https://docs.mongodb.com/manual/tutorial/insert-documents/
```

- Tutoriels :
 - https://docs.mongodb.com/manual/tutorial/
 - http://b3d.bdpedia.fr/docstruct.html#s4-mongodb-une-base-json
 - https://stph.scenari-
 community.org/contribs/nos/Mongol/co/presentation.html
 - https://www.tutorialspoint.com/mongodb/mongodb overview.htm

MongoDB: modèle de données (1/2)

RDBMS	MongoDB
Database	Database
Table	Collection
Tuple/Row	Document
column	Field
Table Join	Embedded Documents
Primary Key	Primary Key (Default key _id provided by mongodb itself)

MongoDB: modèle de données (2/2)

- Document BSON = unité de stockage (~ une ligne dans une BDR)
- Pour l'utilisateur : structure visible en JSON
- Tout document appartient à une collection et a un champ appelé _id qui identifie le document dans la base de données
- Document : hiérarchie de paires clé-valeur, sans contrainte de présence ou de quantité
- Collection : ensemble de documents (~table en relationnel)

MongoDB: exemple

```
first name: 'Paul',
                                           String
                                                            Typed field values
              surname: 'Miller',
                                            Number
             cell: 447557505611,
             city: 'London',
Fields
             location: [45.123,47.232],
                                                                     Fields can contain
             Profession: ['banking', 'finance', 'trader'],
                                                                     arrays
             cars: [
                { model: 'Bentley',
                  year: 1973,
                  value: 100000, ... },
                                                Fields can contain an array of sub-
                                                documents
                { model: 'Rolls Royce',
                  year: 1965,
                  value: 330000, ... }
```

MongoDB: attribut identificateur id

```
id: ObjectId(7df78ad8902c)
title: 'MongoDB Overview',
description: 'MongoDB is no sql database',
by: 'tutorials point',
url: 'http://www.tutorialspoint.com',
tags: ['mongodb', 'database', 'NoSQL'],
likes: 100,
comments: [
      user: 'user1'.
      message: 'My first comment',
      dateCreated: new Date(2011,1,20,2,15),
      like: 0
      user: 'user2',
      message: 'My second comments',
      dateCreated: new Date(2011,1,25,7,45),
      like: 5
```

MongoDB: relationnel vs document

Relationnel

Customer ID	First Name	Last Name	City
0	John	Doe	New York
1	Mark	Smith	San Francisco
2	Jay	White	Dallas
3	Meagan	White	London
4	Edward	Daniels	Boston

Phone Number	Туре	DNC	Customer ID
1-212-555-1212	home	Т	0
1-212-555-1213	home	Т	0
1-212-555-1214	cell	F	0
1-212-777-1212	home	Т	1
1-212-777-1213	cell	(null)	1
1-212-888-1212	home	F	2

MongoDB

```
customer_id : 1,
name : {
  "f": "Mark",
  "1": "Smith" },
 city: "San Francisco",
 phones: [ {
     number: "1-212-777-1212",
     dnc : true,
     type : "home"
},
     number: "1-212-777-1213",
     type : "cell"
}]
```

MongoDB: Relation implémentée par une imbrication de documents

```
"_id":ObjectId("52ffc33cd85242f436000001"),
"contact": "987654321",
"dob": "01-01-1991",
"name": "Tom Benzamin",
"address": [
      "building": "22 A, Indiana Apt",
      "pincode": 123456,
      "city": "Los Angeles",
      "state": "California"
      "building": "170 A, Acropolis Apt",
      "pincode": 456789,
      "city": "Chicago",
      "state": "Illinois"
```

MongoDB: Relation implémentée par l'utilisation de référence

```
{
    "_id":ObjectId("52ffc4a5d85242602e000000"),
    "building": "22 A, Indiana Apt",
    "pincode": 123456,
    "city": "Los Angeles",
    "state": "California"
}
```

```
{
    "_id":ObjectId("52ffc33cd85242f436000001"),
    "contact": "987654321",
    "dob": "01-01-1991",
    "name": "Tom Benzamin",
    "address_ids": [
        ObjectId("52ffc4a5d85242602e000000"),
        ObjectId("52ffc4a5d85242602e000000")
]
}
```

MongoDB: principes

- En général, regroupement de toutes les données relatives à un objet dans un même « document »
- ⇒ nombre de jointures réduit et donc impact positif sur les performances (toutes les données sont récupérées en une seule lecture)
- Document proche de la structure des objets dans les langages de programmation (facilite le développement)
- Modèle des documents pouvant varier de structure dans une même collection
- Schéma dynamique : possibilité d'ajouter de nouveaux champs sans affecter les autres documents
- Schéma flexible mais conçu selon le type de requêtes

MongoDB: opérations CRUD (insertion)

MongoDB: Console et un tutoriel interactif

```
db.inventory.insertOne(
{ item: "canvas", qty: 100, tags: ["cotton"], size: { h: 28, w: 35.5, uom: "cm" } }
)
```

You can run the operation in the web shell below:

```
Click to connect
Connecting...
MongoDB shell version v3.6.0
connecting to: mongodb://127.0.0.1:27017
MongoDB server version: 3.6.0
type "help" for help
>>> db.inventory.insertOne(
... { item: "canvas", qty: 100, tags: ["cotton"], size: { h:
28, w: 35.5, uom: "cm" } }
... )
{
    "acknowledged": true,
    "insertedId": ObjectId("5c66db7c32ab66414816fcd7")
}
>>>
```

MongoDB: opérations CRUD (initialisation ou non de l'attribut _id)

Soit MongoDB crée le champ _id et lui affecte une valeur ObjectId unique

```
db.products.insert( { item: "card", qty: 15 } )
{ "_id" : ObjectId("5063114bd386d8fadbd6b004"), "item" : "card", "qty" : 15 }
```

Soit on crée cet identificateur à l'insertion

MongoDB: opérations CRUD (mixage de la gestion des identificateurs)

```
{ "_id" : 11, "item" : "pencil", "qty" : 50, "type" : "no.2" }
{ "_id" : ObjectId("51e0373c6f35bd826f47e9a0"), "item" : "pen", "qty" : 20 }
{ "_id" : ObjectId("51e0373c6f35bd826f47e9a1"), "item" : "eraser", "qty" : 25 }
```

MongoDB: opérations CRUD (find)

MongoDB: traduction de find en SQL (1/2)

```
db.inventory.find( { status: "D" } )
db.inventory.find( {} )
                                     SELECT * FROM inventory WHERE status = "D"
SELECT * FROM inventory
db.inventory.find( { status: { $in: [ "A", "D" ] } } )
SELECT * FROM inventory WHERE status in ("A", "D")
db.inventory.find( { status: "A", qty: { $lt: 30 } } )
SELECT * FROM inventory WHERE status = "A" AND qty < 30
```

MongoDB: MongoDB: traduction de find en SQL (2/2)

```
db.inventory.find( { status: "A" }, { item: 1, status: 1 } )

SELECT _id, item, status from inventory WHERE status = "A"

db.inventory.find( { status: "A" }, { item: 1, status: 1, _id: 0 } )

SELECT item, status from inventory WHERE status = "A"
```

Attention : Pas d'erreur en cas de faute de frappe sur des noms d'attributs

MongoDB: exemple de tri

```
Query Criteria
    Collection
                                                                       Modifier
db.users.find( { age: { $gt: 18 } } ).sort( {age: 1 } )
  { age: 18, ...}
  { age: 28, ...}
                                    { age: 28, ...}
                                                                    { age: 21, ...}
                                                                    { age: 28, ...}
  { age: 21, ...}
                                   { age: 21, ...}
                                   { age: 38, ...}
  { age: 38, ...}
                                                                    { age: 31, ...}
                  Query Criteria
                                                      Modifier
  { age: 18, ...}
                                    { age: 38, ...}
                                                                    { age: 38, ...}
  { age: 38, ...}
                                    { age: 31, ...}
                                                                    { age: 38, ...}
  { age: 31, ...}
                                                                        Results
      users
```

MongoDB: agrégation

```
Collection
db.orders.aggregate( [
    $group stage --- { $group: { _id: "$cust_id",total: { $sum: "$amount" } } }
   cust_id: "A123",
   amount: 500,
   status: "A"
                                      cust_id: "A123",
                                                                          Results
                                      amount: 500,
                                      status: "A"
   cust_id: "A123",
                                                                         _id: "A123",
   amount: 250,
                                                                         total: 750
   status: "A"
                                      cust_id: "A123",
                                      amount: 250,
                       $match
                                                         $group
                                      status: "A"
   cust_id: "B212",
                                                                         _id: "B212",
   amount: 200.
                                                                         total: 200
   status: "A"
                                      cust_id: "B212",
                                      amount: 200,
                                      status: "A"
   cust_id: "A123",
   amount: 300,
   status: "D"
      orders
```

MongoDB: agrégation en utilisant Map Reduce

```
Collection
db.orders.mapReduce(
                            function() { emit( this.cust_id, this.amount ); },
                           function(key, values) { return Array.sum( values ) },
                             query: { status: "A" },
                             out: "order_totals"
          output -
   cust_id: "A123",
  amount: 500,
  status: "A"
                               cust id: "A123"
                               amount: 500,
                               status: "A"
  cust_id: "A123",
                                                                                           _id: "A123"
  amount: 250,
                                                          "A123": [ 500, 250 ] }
                                                                                           value: 750
  status: "A"
                               cust_id: "A123",
                               amount: 250,
                   query
                               status: "A"
                                                 map
  cust_id: "B212",
                                                         { "B212": 200 }
  amount: 200,
                                                                                           _id: "B212"
   status: "A"
                                                                                           value: 200
                               cust_id: "B212"
                               amount: 200,
                                                                                        order_totals
                               status: "A"
  cust_id: "A123",
  amount: 300,
   status: "D"
     orders
```

MongoDB: opérations CRUD (update)

MongoDB: opérations CRUD (delete)

MongoDB: possibilités de requêtage

- Possibilité de faire des requêtes d'agrégation et d'utiliser map-reduce
- Recherche textuelle
- Gestion de données spatiales
 - Données modélisées en GeoJSON (http://geojson.org/)

```
location: {
    type: "Point",
    coordinates: [-73.856077, 40.848447]
}
```

• Requêtes spatiales (cf. https://docs.mongodb.com/manual/geospatial-queries/)

MongoDB: atomicité

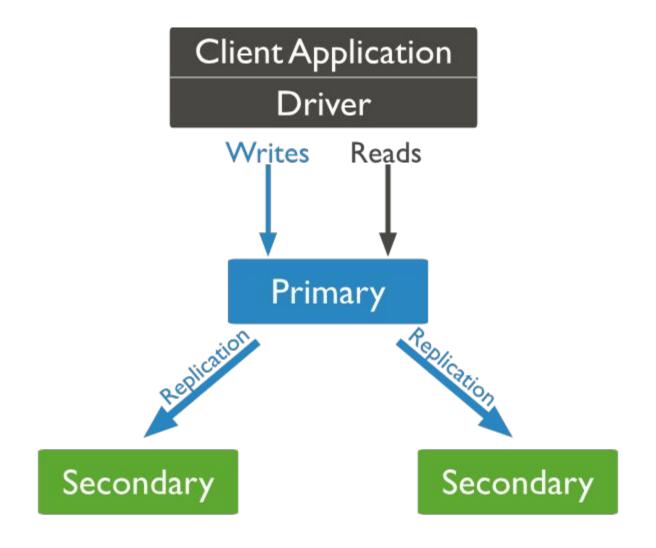
- Ecriture d'un document = opération atomique
- Ecriture de plusieurs documents est atomique pour chacun des documents, mais pas pour l'ensemble
- Ecritures atomiques ⇒ impact sur le design des documents et des collections
- Nécessité de s'assurer de maintenir la cohérence des données

- **Replicat Set** : groupe de processus **mongod** qui fournit la redondance et la haute disponibilité
- Types de membres dans un replicat set:

Primaire: Reçoit toutes les opérations d'écriture

Secondaire: réplication des opérations du primaire pour maintenir des répliques identiques à l'original

Arbitre: ne conserve pas de copie de la donnée, mais joue un rôle dans les élections qui sélectionnent un membre primaire, si le primaire actuel est indisponible



Primaire :

- Seul membre qui reçoit les opérations d'écriture
- MongoDB applique les opérations d'écriture sur le primaire, puis les enregistre dans son log (oplog)
- Les membres secondaires dupliquent ce log et appliquent les opérations sur leurs données
- Tous les membres d'un replicat set peuvent accepter une opération de lecture
- Par défaut, une application dirige ces opérations vers le primaire
- Un replicat set a au plus un primaire
- Si le primaire tombe en panne, une élection a lieu pour en choisir un autre

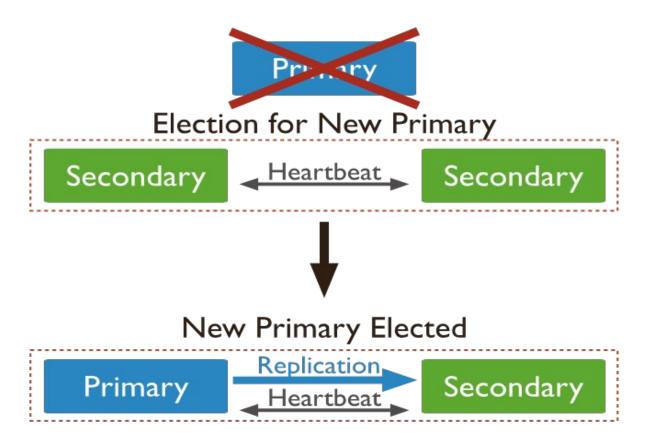
Secondaire :

- Maintiennent une copie des données du primaire
- Pour répliquer les données, un secondaire applique les opérations du oplog du primaire sur ses propres données, de manière asynchrone
- Un replicat set peut avoir un ou plusieurs secondaires
- Même si les clients ne peuvent pas écrire des données sur les secondaires, ils peuvent en lire
- Un secondaire peut devenir un primaire, suite à une élection
- Il est possible de configurer un secondaire :
 - L'empêcher d'être élu pour devenir primaire, lui permettant de rester toujours comme un backup
- Empêcher les applications de lire à partir de lui, lui permettant ainsi de se consacrer à certaines applications nécessitant un trafic séparé

Élections :

- Ont lieu à la création d'un replicat set, ou bien quand un primaire devient indisponible
- Processus qui prend du temps, et qui rend le replicat set en readonly
- Chaque membre a une priorité déterminant son éligibilité à devenir primaire
- L'élection choisit le membre ayant la plus haute priorité comme primaire
- Par défaut, tous les membres ont la même priorité
- Il est possible de modifier la priorité d'un membre ou groupe, selon leur position géographique par exemple.
- Chaque membre a la possibilité de voter pour un seul autre membre
- Le membre recevant le plus grand nombre de votes devient primaire

Élections :



Distribution des données

Le sharding : une méthode de distribution des données sur plusieurs machines pour assurer la scalabilité de l'architecture :

- MongoDB utilise le sharding pour prendre en charge les déploiements avec de très grands ensembles de données et des opérations à haut débit.
- MongoDB prend en charge la **scalabilité horizontale** grâce au sharding.
- Division des données et leur distribution entre plusieurs serveurs ou shards
- Chaque shard est une base indépendante, et mis ensemble, forment une seule base de données logique
- Réduction du nombre d'opérations que chaque machine gère
- Chaque machine gère les données qui y sont stockées
- Réduction de la quantité de données que le serveur a besoin de stocker
- Plus le cluster grandit, moins un serveur contient de données

Distribution des données

Le sharding MongoDB consiste à créer un **Cluster** d'instances MongoDB composée d'au moins trois serveurs:

Shard:

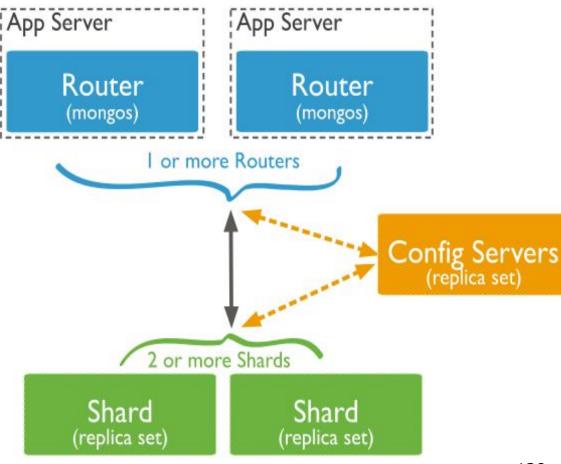
- déployés en tant Replicat set
- Stockent les données
- Les données sont distribuées et répliquées sur les shards

Query Routers :

- Instances mongos
- Interfaçage avec les applications clientes
- Redirige les opérations vers le shard approprié et retourne le résultat au client
- Plusieurs Routers pour la répartition des tâches.
- **ConfigServers :** stockent les métadonnées et les paramètres de configuration pour l'ensemble du cluster.

Distribution des données

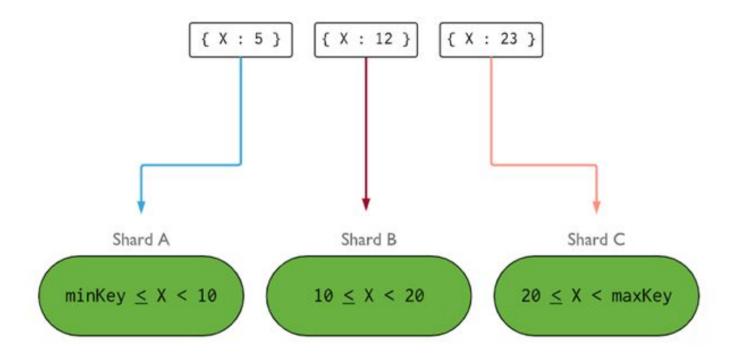
- L'architecture de distribution d'un cluster est schématisée dans la figure ci-dessous :
- 1) L'application cliente communique avec les routeurs (mongos) au sujet de la requête à exécuter.
- 2) L'instance mongos consulte les serveurs de configuration pour vérifier quel Shard contient l'ensemble de données requis et envoyer la requête à ce Shard
- 3) Le résultat de la requête sera renvoyé à l'application.



Fragment de données

■ **fragment de donnees (Chunk)**: sont des sous-ensembles de documents.

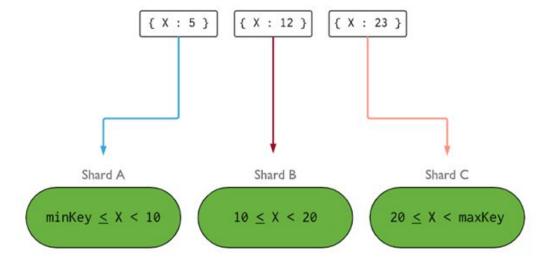
MongoDB sépare les documents d'une collection en fragments (chunks) qui sont distribués sur l'ensemble des shards du cluster.



Clé de partitionnement

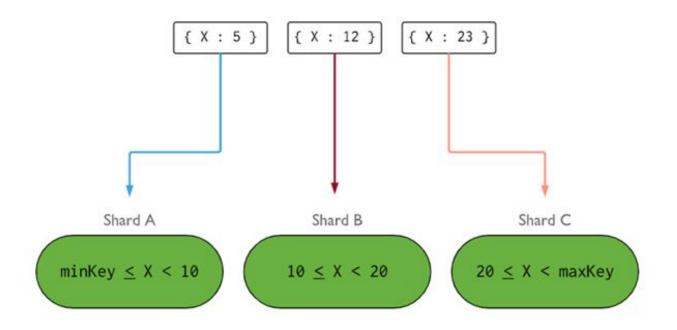
Clé de partitionnement/shard key: Un partitionnement s'effectue toujours en fonction d'une *clé*. MongoDB utilise une clé de partitionnement pour répartir les documents de la collection entre les shards.

- La clé de partitionnement est constituée d'un ou de plusieurs champs des documents.
- Idéalement, on choisira comme clé de partitionnement l'identifiant unique des documents



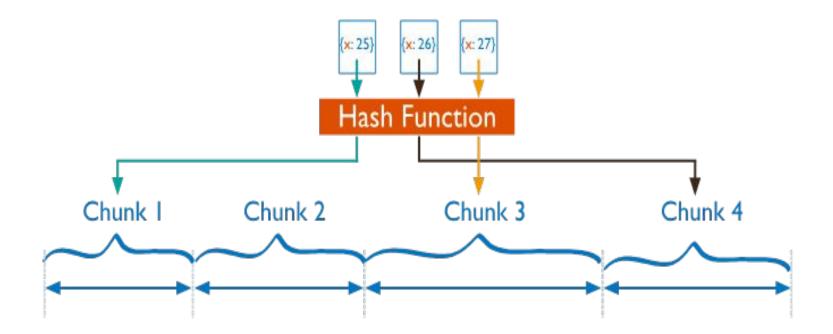
Stratégie de Sharding

■ Ranged Sharding: Le domaine de la clé est partitionné en intervalles semi-ouverts. Chaque intervalle est associé a un fragment stocké sur un shard.



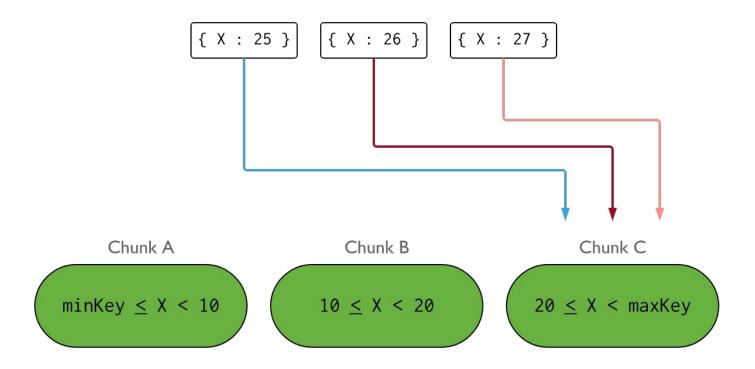
Stratégie de Sharding

■ **Hashed Sharding**: une fonction de hachage est appliquée à la clé de partitionnement qui détermine le fragment d'affectation.



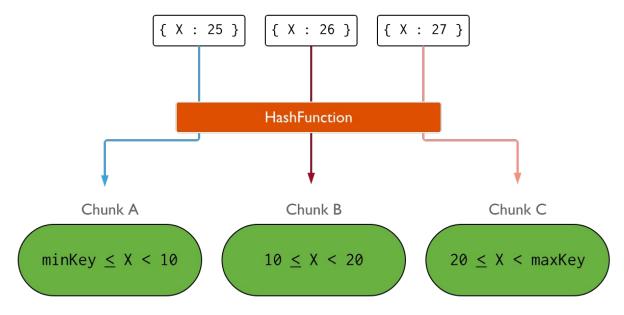
Ranged sharding Vs Hashed Sharding

■ **Hashed Sharding**: Étant donné une collection utilisant une valeur croissante de **X** comme clé de partitionnement, la distribution des insertions entrantes en utilisant ranged sharding est similaire à ce qui suit:



Ranged sharding Vs Hashed Sharding

- Hashed Sharding: Étant donné que la valeur de X est toujours croissante, le fragment dont la limite supérieure est MaxKey reçoit la majorité des écritures entrantes. Cela limite les opérations d'insertion à l'unique shard contenant ce fragment, ce qui réduit l'avantage des écritures distribuées dans un cluster de serveurs.
- En utilisant un index haché sur X, la distribution des insertions est similaire à ce qui suit :



MongoDB: conclusion

- Flexibilité dans le stockage des données
- **Montée en charge**
- **Requêtes**

- **Pas de jointure**
- Transactions (en amélioration)
- Gestion de la mémoire